회귀분석론 HW1

212STG18 예지혜 2021년 3월 1일

1.

```
crime <- read.table("Crime rate.txt")
names(crime) <- c("Y", "X")
head(crime)</pre>
```


	Υ	X
	<int></int>	<int></int>
1	8487	74
2	8179	82
3	8362	81
4	8220	81
5	6246	87
6	9100	66
6 rows		

(a)

```
Im.1 <- Im(Y~X, data = crime)
summary(Im.1)</pre>
```

```
## Call:
## Im(formula = Y ~ X, data = crime)
##
## Residuals:
   Min
             1Q Median 3Q
## -5278.3 -1757.5 -210.5 1575.3 6803.3
##
## Coefficients:
      Estimate Std. Error t value Pr(>|t|)
## (Intercept) 20517.60 3277.64 6.260 1.67e-08 ***
             -170.58 41.57 -4.103 9.57e-05 ***
## X
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 2356 on 82 degrees of freedom
## Multiple R-squared: 0.1703, Adjusted R-squared: 0.1602
## F-statistic: 16.83 on 1 and 82 DF, p-value: 9.571e-05
```

```
plot(crime$X, crime$Y)
lines(crime$X, lm.1$fitted, col=2, lwd=2)
```



적합이 별로 좋지 않아 보인다.

(b)

(1) 진학률 1% 당 범죄 사건 발생이 평균적으로 10,000건 당 170.58건 감소한다.

(2)

```
Im. 1$coefficients[1] + Im. 1$coefficients[2]*80

## (Intercept)
## 6871.585
```

(3)

lm.1\$residuals[10]

```
## 10
## 1401.566
```

(4)

anova(Im.1)[3]

	Mean Sq <dbl></dbl>
х	93462942
Residuals	5552112
2 rows	

 σ^2 의 추정치는 5552112이다.

2.

(a)

summary(Im.1)

```
## Call:
## Im(formula = Y ~ X, data = crime)
##
## Residuals:
    Min
              1Q Median
                            3Q
                                    Max
## -5278.3 -1757.5 -210.5 1575.3 6803.3
##
## Coefficients:
            Estimate Std. Error t value Pr(>|t|)
## (Intercept) 20517.60 3277.64 6.260 1.67e-08 ***
              -170.58
                       41.57 -4.103 9.57e-05 ***
## X
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 2356 on 82 degrees of freedom
## Multiple R-squared: 0.1703, Adjusted R-squared: 0.1602
## F-statistic: 16.83 on 1 and 82 DF, p-value: 9.571e-05
```

```
qt(0.995,df=length(crime$X)-2)
```

[1] 2.637123

$H0: \beta 1 = 0, H1: \beta 1 \neq 0$

t값의 절대값이 4.103으로 기각역인 2.64보다 크므로 귀무가설을 기각한다. 따라서 선형관계가 존재한다고 할 수 있다. p-value는 9.57e-05이다.

(b)

```
c(-170.58-qt(0.995,df=length(crime\$X)-2)*41.57, -170.58+qt(0.995,df=length(crime\$X)-2)*41.57)
```

```
## [1] -280.20522 -60.95478
```

 β 1은 99%의 경우 이 신뢰구간에 포함된다.

(c)

anova(Im.1)

93462942	93462942	16.83376	9.571396e-05
455273165	5552112	NA	NA

(d)

qf(0.99,1,length(crime\$X)-2)

[1] 6.95442

(-4.103)^2

[1] 16.83461

$H0: \beta 1 = 0, H1: \beta 1 \neq 0$

F값은 16.83으로 6.95보다 크므로 귀무가설을 기각한다. 따라서 선형관계는 존재한다.

p-value는 9.571e-05로 (a) t검정과 같은 값을 가지며, t값을 제곱했을 때 F값과 동일한 값이 나오므로 같은 검정임을 알 수 있다.

(e)

```
93462942 + 455273165
```

[1] 548736107

93462942 / (93462942 + 455273165)

[1] 0.170324

X 변수를 통해 총변동에서 SSR (=93462942) 만큼 감소하였다. 총변동에서 X(진학률)이 차지하는 비율은 17.03% 이다. 이 회귀식이 전체의 17% 정도를 설명하므로 큰 비율은 아니라고 해석된다.

(f)

sqrt(summary(Im.1)\$r.squared)

[1] 0.4127033

3.

(a)

full model : Yi=eta 0+eta 1Xi+arepsilon i, arepsilon i are independent $N(0,\sigma 2)$

 $\text{reduced model}: Yi = \beta 0 + \varepsilon i$

(b)

anova(Im.1)

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
	<int></int>	<dbl></dbl>	<dbl></dbl>	<dbl></dbl>	<dbl></dbl>
Х	1	93462942	93462942	16.83376	9.571396e-05
Residuals	82	455273165	5552112	NA	NA

- (1) SSE(F) = SSE = 455273165
- (2) SSE(R) = SST = 93462942 + 455273165 = 548736107
- (3) df(F) = n-2 = 82
- (4) df(R) = n-1 = 83
- $(5) F^* = 16.834$
- (6)

qf(0.99,1,length(crime\$X)-2)

[1] 6.95442

(c) 기각역이 동일하며, F통계량을 제곱하면 t통계량과 같다.

4.

sol <- read.table("Solution concentration.txt")
names(sol) <- c("Y","X")
head(sol)

	Y <dbl></dbl>	X <dbl></dbl>
1	0.07	9
2	0.09	9
3	0.08	9
4	0.16	7
5	0.17	7
6	0.21	7
6 rows		

(a)

Im.2 <- Im(Y~X, data=sol)
summary(Im.2)</pre>

```
## Call:
## Im(formula = Y \sim X, data = sol)
##
## Residuals:
              1Q Median
##
    Min
                           3Q
                                    Max
## -0.5333 -0.4043 -0.1373 0.4157 0.8487
##
## Coefficients:
            Estimate Std. Error t value Pr(>|t|)
## (Intercept) 2.5753 0.2487 10.354 1.20e-07 ***
## X
              -0.3240
                        0.0433 -7.483 4.61e-06 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 0.4743 on 13 degrees of freedom
## Multiple R-squared: 0.8116, Adjusted R-squared: 0.7971
## F-statistic: 55.99 on 1 and 13 DF, p-value: 4.611e-06
```

(b)

```
new <- data.frame(mean=with(tapply(Y, factor(X),mean), data=sol))
new <- data.frame(X= as.numeric(row.names(new)), new)
full <- Im(Y~factor(X), data=sol)
smaller <- Im(Y~X, data=sol)
anova(smaller, full)</pre>
```

	Res.Df <dbl></dbl>	RSS <dbl></dbl>	Df <dbl></dbl>	Sum of Sq <dbl></dbl>	F <dbl></dbl>	Pr(>F) <dbl></dbl>
1	13	2.924653	NA	NA	NA	NA
2	10	0.157400	3	2.767253	58.60342	1.194477e-06
2 rows						

```
qf(0.975,3,10)
```


```
## [1] 4.825621
```

$H0: E(Y) = \beta 0 + \beta 1 Xvs. H1: not H0$

F통계량이 58.603으로 기각역인 4.83보다 크므로 귀무가설을 기각한다. 따라서 1차선형회귀모형은 적합하지 않다.

(c)


```
with(plot(X,Y), data=sol)
lines(sol$X, smaller$fitted, col=3, lwd=2)
with(lines(X,mean, col=2, lwd=2), data=new)
```



문제 (b)에서 lack of fit이 존재한다는 결과가 나왔는데, anova table을 보면, X가 무의미하다고 결론을 내리기에는 무리가 있다. 또한, 그래프를 보면 로그변환이 더 필요해보인다.

(d)

plot(sol\$X, sol\$Y)




(b), 로그변환이 가장 적절해보인다.

(e)

library(car)

Loading required package: carData

 $box_sol < -boxCox(lm.2, lambda = c(-0.2, -0.1, 0, 0.1, 0.2))$



library(ALSM)

Warning: package 'ALSM' was built under R version 3.6.3


Loading required package: leaps

Warning: package 'leaps' was built under R version 3.6.3

Loading required package: SuppDists

Warning: package 'SuppDists' was built under R version 3.6.3

boxcox.sse(solX, solY, = c(-0.2,-0.1,0,0.1,0.2))



lambda <dbl></dbl>	SSE <dbl></dbl>
1 -0.2	0.12353047

	lambda <dbl></dbl>	SSE <dbl></dbl>
2	-0.1	0.06505067
5	0.0	0.03897303
3	0.1	0.04396062
4	0.2	0.08131793
5 rows		

람다가 0일때, 즉 로그 변환이 가장 적합해보인다.


(f)

```
sol$new_Y <- log(sol$Y, base = 10)
new.Im.2 <- Im(new_Y~X, data = sol)
summary(new.Im.2)</pre>
```

```
##
## Call:
## Im(formula = new_Y \sim X, data = sol)
##
## Residuals:
##
        Min
                  1Q Median
                                      3Q
## -0.082958 -0.044421 0.006813 0.033512 0.085550
## Coefficients:
##
               Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.654880 0.026181 25.01 2.22e-12 ***
             -0.195400 0.004557 -42.88 2.19e-15 ***
## X
## ---
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.04992 on 13 degrees of freedom
## Multiple R-squared: 0.993, Adjusted R-squared: 0.9924
## F-statistic: 1838 on 1 and 13 DF, p-value: 2.188e-15
```

(g)


```
plot(sol$X, sol$new_Y)
lines(sol$X, new.lm.2$fitted, col=2, lwd=2)
```



적합이 아주 잘 되어 보인다.

(h)


```
plot(new.lm.2$fitted.values, new.lm.2$residuals)
```



패턴 없이 고르게 잘 분포되어 있으므로 잘 적합되었다고 볼 수 있다.

qqnorm(new.lm.2\$residuals) qqline(new.lm.2\$residuals)

Normal Q-Q Plot



qqplot또한 직선의 형태에 가까우므로 정규성 가정을 해치지 않는다고 볼 수 있다.

(i)
$$Y=10^{(}-0.1954X+0.65488)$$

5.


prod = read.table("Production time.txt")
names(prod) <- c("Y","X")
head(prod)</pre>

	Υ	x
	<dbl></dbl>	<int></int>
1	14.28	15
2	8.80	9

	Y <db ></db >	X <int></int>
3	12.49	7
4	9.38	4
5	10.89	9
6	15.39	21
6 rows		

(a)

```
plot(prod$X, prod$Y)
```



살짝 위로 볼록한 형태를 띠므로 X에 변환이 필요해보인다.


(b)

```
prod$new_X <- sqrt(prod$X)
Im.3 <- Im(Y~new_X, data = prod)
summary(Im.3)</pre>
```

```
## Call:
## Im(formula = Y ~ new_X, data = prod)
##
## Residuals:
##
    Min
              1Q Median
                             3Q
                                    Max
## -5.0008 -1.2161 0.0383 1.3367 4.1795
##
## Coefficients:
             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 1.2547 0.6389 1.964 0.0521.
## new_X
               3.6235
                         0.1895 19.124 <2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 1.99 on 109 degrees of freedom
## Multiple R-squared: 0.7704, Adjusted R-squared: 0.7683
## F-statistic: 365.7 on 1 and 109 DF, p-value: < 2.2e-16
```

(c)


```
plot(prod$new_X, prod$Y)
lines(prod$new_X, lm.3$fitted, col=2, lwd=2)
```



적합이 잘 되어 보인다.

(d)


plot(lm.3\$fitted.values, lm.3\$residuals)



뚜렷한 패턴은 보이지 않는다.

qqnorm(lm.3\$residuals) qqline(lm.3\$residuals)

Normal Q-Q Plot



qqplot은 직선의 형태에 가까우므로 정규성 가정을 해치지 않는다고 볼 수 있다.

(e) $Y=3.6235\sqrt{X}+1.2547$